

Predicción de la Edad de un Abulón a través de Machine Learning

Jorge Manuel Oyoqui Aguilera || A01711783

Inteligencia artificial avanzada para la ciencia de datos

Grupo 601

Profesor Benjamín Valdés Aguirre

30/08/2026

I. Introducción

1.1. Objetivo

El objetivo principal de mi modelo fue lograr predecir la edad de un abulón a través de sus características físicas implementando manualmente todo el proceso de aprendizaje de dicho modelo sin usar ningún framework o biblioteca de Machine Learning. Pero primero entendamos el problema, empezando por saber por qué nos interesaría conocer la edad de un abulón.

1.2. ¿Por qué predecir la edad de un abulón?

Compartiendo algo de contexto, los abulones son moluscos marinos en peligro de extinción que se encuentran en aguas costeras frías de todo el mundo, distribuidos frente a las costas de Nueva Zelanda, Sudáfrica, Australia, el oeste de Norteamérica y Japón. Son alimentos muy nutritivos, elegantes y poco comunes, y se consumen ampliamente en Francia, Nueva Zelanda, ciertas partes de Latinoamérica, Japón y Corea. Las conchas de abulón se utilizan con fines decorativos, por lo que el abulón tiene una gran importancia económica. El precio del abulón está directamente relacionado con su edad. Sin embargo, determinar la edad del abulón es un proceso muy difícil. Se forman anillos en la concha interna del abulón, uno por año. La edad del abulón se determina cortando la concha por la mitad, tiñéndola y contando el número de anillos con un microscopio. [2]

Dado que algunos anillos son difíciles de detectar con este método, tradicionalmente se suma 1,5 al recuento de anillos como una aproximación razonable de la edad del abulón. Conocer el precio absoluto del abulón es importante

tanto para los agricultores como para los consumidores, mientras que conocer la edad correcta es importante para los ambientalistas que buscan proteger esta especie en peligro de extinción. [2]

Ahora, me gustaría aclarar que en mi dataset no había ninguna variable llamada Edad pero, como justamente ya mencioné, la forma más cercana de estimar la edad de un abulón es a través de su número de anillos usando la fórmula:

$$\text{Edad_abulón} = \text{Número_anillos} + 1.5$$

Así que el objetivo de mi modelo va a ser estimar la cantidad de anillos en un abulón a través de sus características físicas.

1.3. Modelo de Machine Learning a usar

Como el objetivo de mi modelo fue predecir el número de anillos (Rings) de un abulón, tuve que decidir con qué tipo de modelo iba a trabajar.

Recordemos que existen dos tipos de aprendizaje en Machine Learning: el aprendizaje supervisado y el no supervisado. En el caso del aprendizaje supervisado, los modelos se entrenan usando un conjunto de datos en el que la respuesta correcta ya se conoce. Con el aprendizaje no supervisado, el conjunto de datos que se usó para el entrenamiento el modelo no contiene la respuesta correcta. [3]

Como en mi dataset si poseo el valor correcto de la cantidad de anillos de cada abulón, entonces eso significaba que trabajaría con un modelo de **algoritmo de aprendizaje supervisado**.

Este tipo de algoritmos de aprendizaje supervisado se dividen en dos tipos de problemas: de regresión y de clasificación. Los problemas de clasificación son aquellos donde el resultado esperado es una categoría o clase, mientras que en los problemas de regresión lo que se espera es la predicción de un valor continuo. [3]




Figura 1. Algoritmos de clasificación y regresión

En mi caso, como voy a estar intentando predecir el valor de la variable *Rings*, es decir, un valor continuo, entonces el tipo de algoritmo que trabajaré para mi modelo fue uno de **regresión lineal múltiple** (múltiple debido a las múltiples variables independientes con las que trabajé).

Ahora, como no voy a poder utilizar frameworks, necesito un método de optimización para poder modificar y actualizar los pesos y el bias poco a poco para entrenar mi modelo y así reducir el MSE. Es ahí donde entra el Gradiente Descendente, con el cual decidí trabajar.

Así que, en general, con eso decidí que el modelo con el que iba a estar trabajando iba a ser un modelo de Regresión Lineal Múltiple con Gradiente Descendente.

Con eso claro, pasemos a la siguiente parte.

II. ETL

2.1. ¿Qué es ETL?

Cuando hablamos de Machine Learning, las siglas ETL significan extracción, transformación y carga de los datos. Este proceso es fundamental ya que es la fase para preparar, organizar y limpiar los datos que se usarán más adelante para entrenar y probar mi modelo. De esta forma, me aseguraré de tener datos limpios que el modelo pueda usar, que no posea inconsistencias o sesgos y que se puedan usar para mi análisis.

2.2. Mi dataset

Para este proyecto, usé el dataset conocido como *abalone*, el cual se encuentra disponible en la siguiente liga: <https://archive.ics.uci.edu/dataset/1/abalone>.

El dataset proporciona la información de las características de los diferentes abulones que se

estudiaron, las cuales serán usadas para predecir los valores de la variable *Rings*. Este dataset contiene en total 4177 instancias, cada una representando a un abulón diferente. Posee 9 características que describen las cualidades físicas de cada abulón. A continuación, explico más detalladamente qué representa cada variable:

Característica	Descripción
Sex	El sexo del abulón. Se clasifica en M (male), F (female) e I (infant)
Length	Medida de la longitud máxima de la concha (en mm)
Diameter	Medida perpendicular a la longitud (en mm)
Height	La altura con la carne dentro de la concha (en mm)
Whole weight	Peso del abulón completo (en gramos)
Shucked weight	Peso de la carne sin la concha (en gramos)
Viscera weight	Peso del tracto digestivo tras el desangrado (en gramos)
Shell weight	Peso de la concha tras el secado (en gramos)
Rings	Número de anillos en la concha del abulón. +1.5 indica la edad en años del abulón (valor a predecir)

2.3. Carga del dataset

Primero, descargué el dataset de UC Irvine Machine Learning Repository de la liga que antes compartí, para posteriormente usar la librería de pandas para cargar los datos en un dataframe llamado *df* y nombrar sus columnas según correspondiera con la variable cuyos datos iba a contener.

2.4. Limpieza de los datos

2.4.1. Detección de valores inválidos

Luego de cargar los datos en el dataset, empecé a revisar los datos hasta que me di cuenta de que el valor mínimo de la variable *Height* era exactamente de cero. Eso no debía ser correcto, así que decidí investigar más a fondo y buscar todas las instancias con un valor de *Height* = 0. Al final, obtuve dos resultados. Tenía la hipótesis de que se iban a tratar de instancias donde todos sus valores fueran de cero, pero resultó no ser así. Los únicos datos con cero eran sus alturas. Como esos datos iban a ser problemáticos, al ser solamente dos instancias de 4177, decidí mejor eliminarlas al tratarse de sólo un 0.048% del total de mis datos.

2.4.2. Detección de valores nulos

Revisé si mi dataset poseía alguna instancia con valores nulos. Afortunadamente, ninguna tenía valores nulos, así que ahí no tuve que hacer ninguna limpieza.

2.4.3. Detección de outliers

Lo siguiente fue buscar posibles valores outliers en mi dataset. Para ello, generé una variable para guardar las columnas con un data type flotante o entero, sin contar a la columna de Rings, ya que esa era la variable objetivo. Posteriormente, generé una lista para guardar a los posibles outliers que fuera a encontrar.

Usé el rango intercuartílico de modo que si mi código llegaba a encontrar una instancia con algún valor que se encontrara en:

$$Cota_inferior = Q1 - 1.5 * IQR$$

o

$$Cota_superior = Q3 + 1.5 * IQR$$

sería tomado como outlier y almacenado en la lista anteriormente mencionada.

Al final, el número de posibles outliers encontrados fue de 151, así que lo siguiente por hacer fue decidir qué iba a hacer con esos outliers. Mi primera opción fue eliminarlos, pero consideré que estaría perdiendo varios datos, aún si sólo se trataba del 3.66% del total de datos (contando los dos registros con Height=0 que eliminé previamente). Luego, me llegó la suposición de que dichos outliers podían tratarse de abulones o muy pequeños o muy grandes. Así que para comprobarlo, decidí revisar manualmente a los outliers y ver si sus datos eran consistentes entre sí.

Referencias bibliográficas

- [1] Ashok Kumar Palivela (2021). "Predicción de la edad del abulón". Recuperado de: <http://kaggle.com/code/ashokkumarpalivela/abalone-age-prediction>
- [2] Harshitha Indumathi (2021). "Predicción de la edad del abulón". Recuperado de: <https://harshithaindumathi.medium.com/abalone-age-prediction-607ecda3fa3b>
- [3] Brayan Buitrago (2020). "Aprendizaje automático — Modelos de Regresión I". Recuperado de: <https://medium.com/iwannabedatadriven/machine-learning-modelos-de-regresi%C3%B3n-i-d293ae235e9a>
- [4] Khan Academy (S.F.). "Descenso de gradiente". Recuperado de: <https://es.khanacademy.org/math/multivariable-calculus/applications-of-multivariable-derivatives/optimizing-multivariable-functions/a/what-is-gradient-descent>
- [5] AWS (2022). "¿Qué es extracción, transformación y carga (ETL)?". Recuperado de: <https://aws.amazon.com/es/what-is/etl/>
- [6] Informatica (S.F.). "¿Qué es ETL (extracción, transformación y carga)?". Recuperado de: <https://www.informatica.com/resources/articles/what-is-etl.html>
- [7]